

周报，2021年07月05日

屈原斌
首都师范大学
ybqu@cnu.edu.cn

1 上周计划

1. 标题-正文匹配实验更新
2. 代码封装
3. 更新Demo

2 上周计划执行情况

1. [×]
2. [×]
3. [×] Demo数据库问题未解决

3 本周部分重点工作详述

3.1 标题-正文匹配实验更新

- 数据集：
 - 构造三档数据
 - * 构造方法，见图1
 - 1. 优 - 乐乐课堂/笔神作文
 - 2. 良 - 计算正文相似度，随机选择相似度较小作文，随机替换部分作文
 - 3. 中 - 计算正文相似度，随机选择相似度较小作文，替换正文
 - * 数据分布，见表1




Figure 1: 数据集构造方法

• 实验策略：

1. 策略一：BERT-Gen HT(无监督)
 - * 使用bert生成模型获取表示，检索相应标题，计算相似度
 - baseline: 使用TFIDF和主题词计算相似度

	优	良	中	合计	数据来源
训练集	12000	3000	3000	18000	
验证集	500	50	50	600	乐乐课堂，随机替换标题
测试集	Dataset_1	202	127	78	407 同步作文（199原始数据+208篇构造数据，双标）
	Dataset_2	2000	200	200	2400 乐乐课堂，随机替换标题

Table 1: 数据集分布

2. 策略二：BERT-NSP

* 使用BertNSP做二分类任务

3. 策略三：Attention sum reader

* 使用SPP

	阈值	模型预测						优	良	中	
		Acc	Marco-F1	跨二档率	相关系数	P	R				
Baseline	-	0.75 / 0.85	0.4767	0.3900	0.1302	0.2546	0.5547	0.7277	0.6296	0.3236	0.2362
BERT-Gen(Topk相似度取最大值)	CLS	Topk=50 / 0.60 / 0.80	0.4939	0.4571	0.1081	0.3439	0.6685	0.6089	0.6373	0.3577	0.3465
	LastAvg	Topk=100 / 0.60 / 0.80	0.5037	0.4388	0.0934	0.3336	0.6635	0.6832	0.6732	0.3566	0.3622
BERT-NSP			0.4914	0.3136	0.1304	-	0.5184	0.9059	0.6595	0.2593	0.0551
ASReader			0.5184	0.3310	0.1400	-	0.5245	0.9554	0.6772	0.0000	0.0000

Table 2: Dataset₁指标更新

	阈值	模型预测						优	良	中	
		Acc	Marco-F1	跨二档率	P	R	F				
BERT-NSP	0.8650	0.6838	0.0804	0.9257	0.9215	0.9236	0.4588	0.3900	0.4216	0.6485	0.7750
ASReader	0.8400	0.5258	0.1302	0.8880	0.9435	0.9149	0.4091	0.0900	0.1475	0.4805	0.5550

Table 3: Dataset₂指标更新

4 下周计划

1. [***] 补充实验（尝试生成模型与NSP结合）
2. [***] 更新Demo