2021年04月25日进度汇报

屈原斌 首都师范大学 ybqu@cnu.edu.cn

- 1 今日进度
 - 1. 更新离题检测实验
 - 2. 中文离题测试集处理
- 2 工作详述
 - 实验数据:
 - ICLE数据集, 11个主题, 共827篇作文, 离题:切题=51:776(1:15)
 - 实验方案:
 - 聚类方案一:
 - * 计算聚类结果中可能离题的类与范文类的相似度
 - * 修改调参方式: distance_threshold从0-1以0.05步长调参, example_threshold大类按照 比例调参 (对所有类按照作文数排序, 当大类包含作文数占比大于阈值时停止)
 - . 问题: 对于相同大小的类排序(先后顺序不同,可能会影响最终的结果)
 - * 阈值与R@10/R@all(全部小类作文中离题作文的Recall)变化趋势见图1、图2
 - * 实验结果见表1
 - * 结论(tf-idf结果未跑完):
 - · 有一些作文通过调参召回不了
 - 聚类方案二 (one-class):
 - * 计算全部作文与它们的质心的相似度,指标见表2
 - * 结论:
 - ·bert分类模型指标最优
 - 聚类方案三(Prompt-independent)
 - * 指标见表3
 - * 结论:
 - 聚类方案四:(未完成)
 - * 计算作文与prompt的相似度,进行排序

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
baseline		0.5334	0.5334	0.6546	0.7548	0.8225	0.3636	0.3091	0.2727	0.2007
tfidf										
doc2vec		0.5334	0.6243	0.6296	0.6888	0.7459	0.2727	0.2727	0.2727	0.1355
分类模型	lstm	0.4842	0.5023	0.5259	0.6207	0.6635	0.4545	0.2545	0.2364	0.1676
	bert	0.5995	0.5995	0.6298	0.7064	0.7545	0.2727	0.2727	0.2727	0.1777
生成模型	lstm	0.4189	0.4319	0.4319	0.6191	0.6191	0.0000	0.1273	0.2182	0.0009
	bert	0.4944	0.4998	0.4998	0.5105	0.5319	0.3636	0.2545	0.2364	0.0420

R@all 表示全部小类中离题的召回

Table 1: 聚类方案一指标更新

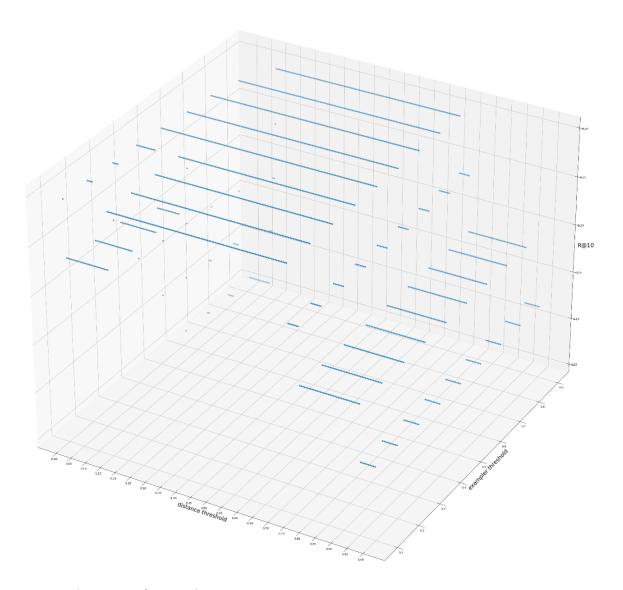


Figure 1: 阈值对R@10的影响 (Topic : Most University degrees are theoretical and do not prepare us for the real life. Do you agree or disagree)

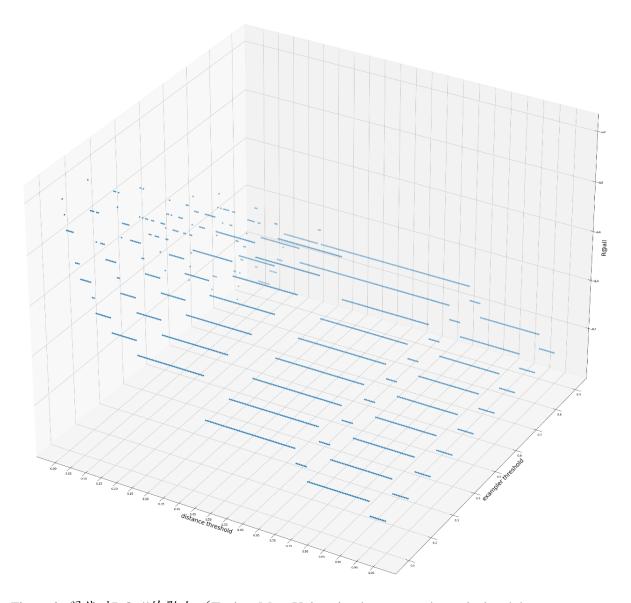


Figure 2: 闽值对R@all的影响 (Topic : Most University degrees are theoretical and do not prepare us for the real life. Do you agree or disagree)

		R@10	R@15	R@20	R@50	P@1	P@5	P@10	spearman
baseline		0.3917	0.4631	0.5594	0.7148	0.4545	0.2909	0.2182	0.1429
tfidf		0.4350	0.4533	0.5041	0.7558	0.4545	0.3091	0.2364	0.2437
doc2vec		0.3865	0.4381	0.5291	0.7041	0.5455	0.2727	0.2182	0.1865
分类模型	lstm	0.3728	0.4062	0.4479	0.7398	0.4545	0.2727	0.1909	0.1535
万天侯王	bert	0.3029	0.4480	0.5419	0.7344	0.2727	0.2182	0.1818	0.0960
生成模型	lstm	0.1263	0.2463	0.3676	0.7041	0.0000	0.0727	0.0818	-0.0039
	bert	0.5259	0.5389	0.5389	0.7504	0.3636	0.2364	0.2636	0.1266

Table 2: 聚类方案二 (one-class) 指标更新

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
baseline		0.3165	0.3498	0.3552	0.5780	0.6208	0.1818	0.2364	0.1636	0.0492
tfidf										
doc2vec		0.2528	0.3316	0.3316	0.6190	0.6404	0.0909	0.2000	0.1455	0.1257
分类模型	lstm	0.1944	0.2482	0.2967	0.4090	0.4518	0.2727	0.1455	0.1182	0.0501
	bert	0.2977	0.3432	0.4038	0.6017	0.6337	0.2727	0.2182	0.1818	0.1308
生成模型	lstm	0.0766	0.1426	0.1715	0.2231	0.2392	0.0000	0.0545	0.0455	0.0009
	bert	0.3873	0.4480	0.4533	0.4943	0.5103	0.2727	0.2545	0.1909	0.0662

R@all 表示全部小类中离题的召回

Table 3: 聚类方案三(prompt-independent)指标更新