

## Contents

# 2021年05月04日进度汇报

屈原斌  
首都师范大学  
ybqu@cnu.edu.cn

## 1 今日进度

### 1. 更新离题检测实验

- 更新 whitening 指标
  - \* whitening在方案一、三上指标提升
- 更新中文测试集 (部分实验还没有跑完)

## 2 工作详述

### • 实验数据(详细信息见附录):

- 英文: ICLE数据集, 11个主题, 共827篇作文, 离题:切题=51:776 (1:15)
- 中文: 智学网初中作文数据, 10个主题 (35个主题, 随机选了10个主题), 共5498篇作文, 离题:切题=350:5148 (1:14.7)

### • 实验方案:

#### - 聚类方案一:

- \* 计算聚类结果中可能离题的类与范文类的相似度, 实验结果见表1
  - 调参方式:
    - distance\_threshold: 从0-1以0.05步长调参
    - example\_threshold: 大类按照比例调参 (对所有类按照作文数排序, 当大类包含作文数占比大于阈值时停止)
- \* linkage取不同参数时指标对比 (doc2vec), 实验结果见表2
- \* 结论:
  - linkage取complete (最大值) 时指标最优
  - ? bert生成/分类模型, 取不同表示时结论不一致
  - ! 不同表示下spearman相关系数差别较大:
    - 不同表示下相同主题指标最优时小类的作文数不同, 会导致一些作文相似度计算方式不同 (小类中的作文, 取与大类距离的最小值; 大类中作文, 取与自己类质心的相似度)
    - 大类和小类一起排序可能会改变原来的顺序 (单独计算大小类的spearman相关系数波动较大)

#### - 聚类方案二 (one-class):

- \* 计算全部作文与它们的质心的相似度, 实验结果见表3
- \* 结论:
  - bert生成模型指标最优

#### - 聚类方案三 (Prompt-independent)

- \* 五折交叉验证, 使用开发集调参, 测试集测试, 实验结果见表4

- \* 结论：
  - 使用开发集的参数测试集测试时，部分主题没有小类（和划分范文类策略相关）
- 聚类方案四
  - \* 计算作文与prompt的相似度，进行排序，实验结果见表5
- 结论：
  - \* bert生成模型指标最优

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	baseline	0.5334	0.5334	0.6546	0.7548	0.8225	0.3636	0.3091	0.2727	0.2007
	tfidf	0.5009	0.5009	0.5517	0.6875	0.7446	0.3636	0.2727	0.2636	0.1866
	doc2vec	0.5334	0.6243	0.6296	0.6888	0.7459	0.2727	0.2727	0.2727	0.1355
分类模型	lstm	0.4842	0.5023	0.5259	0.6207	0.6635	0.4545	0.2545	0.2364	0.1676
	bert_CLS	0.5995	0.5995	0.6298	0.7064	0.7545	0.2727	0.2727	0.2727	0.1776
	bert_CLS(+whitening)	0.6093	0.6449	0.6449	0.7055	0.8000	0.1818	0.2727	0.2636	0.1426
	bert_Last1avg	0.5540	0.6752	0.7358	0.7465	0.7947	0.3636	0.2727	0.2818	0.1977
	bert_Last1avg(+whitening)	0.7002	0.7358	0.7412	0.7768	0.8303	0.3636	0.2909	0.3000	0.2111
	bert_Last2avg	0.5540	0.6752	0.6752	0.7647	0.8128	0.2727	0.2909	0.2818	0.1745
生成模型	bert_Last2avg(+whitening)	0.5357	0.5357	0.6266	0.6911	0.7392	0.1818	0.2727	0.2636	0.1551
	lstm_h <sub>t<sub>n</sub></sub>	0.3781	0.3834	0.3834	0.4979	0.5460	0.0909	0.1636	0.2000	0.0792
	lstm_avg	0.4394	0.4697	0.4697	0.6016	0.6658	0.2727	0.2182	0.2182	0.1148
	lstm_h <sub>t<sub>n</sub></sub> (+作文)	0.4189	0.4319	0.4319	0.6191	0.6191	0.0000	0.1273	0.2182	0.0009
	lstm_avg(+作文)	0.4582	0.4635	0.4635	0.4999	0.4999	0.0909	0.1455	0.1818	0.0264
	bert_CLS	0.4526	0.4579	0.4579	0.4579	0.4579	0.1818	0.2000	0.1818	0.1146
	bert_CLS(+whitening)	0.5963	0.5963	0.6319	0.7531	0.8066	0.3636	0.2545	0.2727	0.1594
	bert_CLS(+作文)	0.4944	0.4998	0.4998	0.5105	0.5319	0.3636	0.2545	0.2364	0.0420
	bert_CLS(+作文,+whitening)	0.6038	0.6038	0.6038	0.7592	0.7753	0.0909	0.2545	0.2818	0.0800
	bert_Last1avg	0.5500	0.6409	0.6560	0.6863	0.6863	0.4545	0.2545	0.2545	0.1250
	bert_Last1avg(+whitening)	<b>0.7023</b>	0.7023	0.7023	0.7433	0.7487	0.2727	0.2727	0.2909	0.1523
	bert_Last1avg(+作文)	0.4739	0.4793	0.4793	0.5256	0.5310	0.4545	0.2727	0.2273	0.0324
	bert_Last1avg(+作文,+whitening)	0.6925	0.6925	0.7228	0.7517	0.7892	0.3636	0.3091	0.3000	0.2039

R@all 表示全部小类中离题的召回

+作文 表示在作文数据上进行微调（原始模型使用新闻数据预训练）

+whitening 表示使用Bert-whitening对表示进行变换

\* lstm\_h<sub>t<sub>n</sub></sub> 表示取Lstm最后时刻的表示，lstm\_avg 表示取Lstm所有时刻的表示平均

Table 1: 聚类方案一指标更新（英文）

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	tfidf									
	doc2vec	0.2185	0.3183	0.3902	0.8091	0.9190	0.8000	0.8000	0.7500	0.6813
分类模型	lstm	0.2054	0.2975	0.3949	0.8509	0.9632	0.6000	0.7200	0.7000	0.7036
	lstm(+测试主题)	0.2078	0.3052	0.4010	0.8346	0.9225	0.8000	0.7600	0.7200	0.6853
	bert.CLS									
	bert.CLS(+whitening)									
	bert.CLS(+测试主题)									
	bert.CLS(+测试主题,+whitening)									
生成模型	bert.Last1avg	0.2053	0.3038	0.3886	0.7581	0.8610	0.7000	0.6600	0.7000	0.6629
	bert.Last1avg(+whitening)									
	bert.Last1avg(+测试主题)	0.2158	0.3199	0.4128	0.8339	0.9565	0.9000	0.8200	0.7300	0.7060
	bert.Last1avg(+测试主题,+whitening)									
	lstm.h <sub>tn</sub>	0.1534	0.2230	0.3174	0.7315	0.8548	0.5000	0.4000	0.5500	0.6310
	lstm.avg	0.2063	0.2900	0.3893	0.7935	0.9107	0.7000	0.6800	0.7200	0.7018
生成模型	bert.CLS	0.1896	0.2744	0.3540	0.7248	0.8743	0.8000	0.7000	0.6600	0.6063
	bert.CLS(+whitening)									
	bert.CLS(+测试作文)	0.0351	0.0523	0.0724	0.1276	0.1866	0.3000	0.1400	0.1300	0.0361
	bert.CLS(+测试作文,+whitening)									
	bert.Last1avg	0.1674	0.2369	0.3258	0.6856	0.8351	0.7000	0.6200	0.5800	0.5955
	bert.Last1avg(+whitening)									
生成模型	bert.Last1avg(+测试作文)	0.0543	0.0716	0.0791	0.1349	0.2437	0.5000	0.2800	0.2100	0.0522
	bert.Last1avg(+测试作文,+whitening)									

+测试主题 表示在测试主题继续训练分类模型；+测试作文 表示在测试集上继续训练生成模型

\* lstm.h<sub>tn</sub> 表示取Lstm最后时刻的表示，lstm.avg 表示取Lstm所有时刻的表示平均

Table 2: 聚类方案一指标更新（中文）

	R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
linkage='average'	0.5334	0.6243	0.6296	0.6888	0.7459	0.2727	0.2727	0.2727	0.1355
linkage='complete'	0.6849	0.6849	0.6902	0.7312	0.7883	0.2727	0.3091	0.3000	0.1504
linkage='single'	0.5001	0.6061	0.6061	0.6781	0.7459	0.4545	0.2727	0.2545	0.1573

linkage='average': 取平均；linkage='complete': 取最大值；linkage='single': 取最小值；

Table 3: linkage取不同参数时指标对比（英文，doc2vec）

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	baseline	0.3917	0.4631	0.5594	0.7148	-	0.4545	0.2909	0.2182	0.1429
	tfidf	0.4350	0.4533	0.5041	0.7558	-	0.4545	0.3091	0.2364	0.2437
	doc2vec	0.3865	0.4381	0.5291	0.7041	-	0.5455	0.2727	0.2182	0.1865
分类模型	lstm	0.3728	0.4062	0.4479	0.7398	-	0.4545	0.2727	0.1909	0.1535
	bert.CLS	0.3029	0.4480	0.5419	0.7344	-	0.2727	0.2182	0.1818	0.0960
	bert.CLS(+whitening)	0.2977	0.3918	0.4578	0.7398	-	0.2727	0.1636	0.1636	0.1833
	bert.Last1avg	0.3635	0.4480	0.4934	0.7291	-	0.3636	0.2364	0.2000	0.1101
	bert.Last1avg(+whitening)	0.3637	0.4221	0.4631	0.7451	-	0.3636	0.2364	0.2000	0.2126
	bert.Last2avg	0.3582	0.4176	0.4631	0.7291	-	0.2727	0.2545	0.1909	0.1189
生成模型	bert.Last2avg(+whitening)	0.3084	0.3873	0.4381	0.6381	-	0.2727	0.2364	0.1909	0.1725
	lstm.h <sub>tn</sub>	0.1826	0.2850	0.4062	0.6684	-	0.0909	0.1273	0.1091	0.0156
	lstm.avg	0.3455	0.3736	0.4070	0.6025	-	0.1818	0.1636	0.1818	0.0765
	lstm.h <sub>tn</sub> (+作文)	0.1263	0.2463	0.3676	0.7041	-	0.0000	0.0727	0.0818	-0.0039
	lstm.avg(+作文)	0.1792	0.3394	0.4788	0.7023	-	0.0909	0.1273	0.1000	-0.0041
	bert.CLS	0.3476	0.6214	0.6820	0.8503	-	0.1818	0.2182	0.1818	0.1516
	bert.CLS(+whitening)	0.4371	0.4813	0.5570	0.7344	-	0.2727	0.2909	0.2091	0.1300
	bert.CLS(+作文)	0.5259	0.5389	0.5389	0.7504	-	0.3636	0.2364	0.2636	0.1266
	bert.CLS(+作文,+whitening)	0.3810	0.4373	0.5184	0.6988	-	0.2727	0.2727	0.1909	0.1038
	bert.Last1avg	0.3393	0.5328	0.6873	0.8449	-	0.4545	0.2182	0.1727	0.1026
	bert.Last1avg(+whitening)	0.3152	0.4547	0.5335	0.7594	-	0.2727	0.2182	0.1727	0.1071
	bert.Last1avg(+作文)	0.5107	0.5389	0.5389	0.7451	-	0.3636	0.2909	0.2545	0.1280
	bert.Last1avg(+作文,+whitening)	0.3658	0.4827	0.5736	0.8004	-	0.2727	0.2000	0.1909	0.1177

R@all 表示全部小类中离题的召回

+作文 表示在作文数据上进行微调（原始模型使用新闻数据预训练）

+whitening 表示使用Bert-whitening对表示进行变换

\* lstm.h<sub>tn</sub> 表示取Lstm最后时刻的表示，lstm.avg 表示取Lstm所有时刻

Table 4: 聚类方案二（one-class）指标更新（英文）

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	tfidf	0.0621	0.0956	0.1138	0.2151	-	0.2000	0.2400	0.2300	0.0956
	doc2vec	0.0428	0.0594	0.0962	0.2191	-	0.2000	0.1400	0.1600	0.1057
分类模型	lstm	0.0615	0.0905	0.1072	0.2314	-	0.4000	0.2600	0.2300	0.1343
	lstm(+测试主题)	<b>0.1038</b>	0.1479	0.1781	0.3175	-	0.5000	0.4600	0.3700	0.1616
	bert_CLS	0.0624	0.0894	0.1006	0.2223	-	0.6000	0.2400	0.2200	0.1106
	bert_CLS(+whitening)	0.0236	0.0415	0.0605	0.1893	-	0.1000	0.1000	0.0900	0.0995
	bert_CLS(+测试主题)	0.0677	0.0837	0.1136	0.2448	-	0.2000	0.3200	0.2500	0.1454
	bert_CLS(+测试主题,+whitening)	0.0619	0.0744	0.1000	0.2204	-	0.4000	0.2600	0.2300	0.1266
	bert_Last1avg	0.0611	0.0811	0.1022	0.2172	-	0.3000	0.2400	0.2100	0.0991
	bert_Last1avg(+whitening)	0.0622	0.0834	0.1033	0.2103	-	0.4000	0.2800	0.2300	0.1060
生成模型	bert_Last1avg(+测试主题)	0.0853	0.1217	0.1462	0.2877	-	0.5000	0.3200	0.2900	0.1725
	bert_Last1avg(+测试主题,+whitening)	0.0796	0.1097	0.1378	0.3037	-	0.5000	0.3000	0.2900	0.1650
	lstm_h <sub>tn</sub>	0.0129	0.0241	0.0292	0.1073	-	0.0000	0.0600	0.0500	0.0086
	lstm_avg	0.0526	0.0751	0.0930	0.1964	-	0.3000	0.2400	0.1900	0.0977
	bert_CLS	0.0669	0.0878	0.1111	0.2064	-	0.3000	0.3000	0.2500	0.0624
	bert_CLS(+whitening)	0.0793	0.0987	0.1162	0.2312	-	0.5000	0.4000	0.2900	0.0848
	bert_CLS(+测试作文)	0.0337	0.0472	0.0639	0.1519	-	0.1000	0.1600	0.1300	0.0162
	bert_CLS(+测试作文,+whitening)	0.0630	0.0841	0.0957	0.2028	-	0.3000	0.2600	0.2300	0.0624
生成模型	bert_Last1avg	0.0566	0.0721	0.0787	0.1745	-	0.1000	0.2000	0.2000	0.0564
	bert_Last1avg(+whitening)	0.0593	0.0842	0.1106	0.2061	-	0.3000	0.2200	0.2200	0.0828
	bert_Last1avg(+测试作文)	0.0495	0.0628	0.0726	0.1507	-	0.5000	0.2800	0.1900	0.0280
	bert_Last1avg(+测试作文,+whitening)	0.0669	0.0878	0.1037	0.2074	-	0.1000	0.2000	0.2400	0.0646

+测试主题 表示在测试主题继续训练分类模型; +测试作文 表示在测试集上继续训练生成模型

\* lstm\_h<sub>tn</sub> 表示取Lstm最后时刻的表示, lstm\_avg 表示取Lstm所有时刻的表示平均

Table 5: 聚类方案二 (one-class) 指标更新 (中文)

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	baseline	0.1070	0.1070	0.1123	0.3351	0.3779	0.0000	0.0909	0.0545	0.0197
	tfidf	0.0667	0.0667	0.0970	0.1758	0.1758	0.0909	0.0545	0.0273	0.0233
	doc2vec	0.1468	0.2256	0.2256	0.5129	0.5343	0.0909	0.1273	0.0909	0.1160
分类模型	lstm	0.0645	0.1184	0.1668	0.2791	0.3219	0.0909	0.0182	0.0455	0.0089
	bert_CLS	0.2371	0.2674	0.3280	0.5259	0.5580	0.1818	0.1636	0.1455	0.1018
	bert_CLS(+whitening)	0.2576	0.2986	0.2986	0.5517	0.5892	0.0909	0.1636	0.1455	0.0950
	bert_Last1avg	0.1982	0.2285	0.2891	0.5119	0.5386	0.2727	0.1636	0.1182	0.0908
	bert_Last1avg(+whitening)	0.2145	0.3539	0.3895	0.5517	0.5785	0.1818	0.1636	0.1364	0.0739
	bert_Last2avg	0.2231	0.2891	0.3194	0.5172	0.5333	0.1818	0.1636	0.1182	0.0960
生成模型	bert_Last2avg(+whitening)	0.1527	0.1527	0.1830	0.3256	0.3577	0.0909	0.1455	0.0909	0.0329
	lstm_h <sub>tn</sub>	0.1273	0.2182	0.2182	0.2699	0.2752	0.0909	0.0545	0.0636	0.0045
	lstm_avg	0.1857	0.2062	0.2365	0.3631	0.3952	0.0000	0.1273	0.1000	0.0418
	lstm_h <sub>tn</sub> (+作文)	0.0766	0.1426	0.1715	0.2231	0.2392	0.0000	0.0545	0.0455	0.0009
	lstm_avg(+作文)	0.1447	0.1750	0.2053	0.2517	0.2731	0.0909	0.0909	0.0727	-0.0207
	bert_CLS	0.3501	0.3554	0.3661	0.3715	0.3715	0.1818	0.1636	0.1182	0.1271
	bert_CLS(+whitening)	0.2452	0.3195	0.3801	0.5174	0.6511	0.2727	0.1636	0.1273	0.0635
	bert_CLS(+作文)	0.3873	0.4480	0.4533	0.4943	0.5103	0.2727	0.2545	0.1909	0.0662
	bert_CLS(+作文,+whitening)	<b>0.3885</b>	0.4143	0.4143	0.5894	0.7070	0.3636	0.2364	0.2000	0.0692
	bert_Last1avg	0.2549	0.3390	0.4602	0.6224	0.6331	0.2727	0.2182	0.1273	0.0413
生成模型	bert_Last1avg(+whitening)	0.1937	0.3937	0.4421	0.5067	0.5281	0.2727	0.1273	0.1091	0.0036
	bert_Last1avg(+作文)	0.3009	0.3062	0.3971	0.4078	0.4078	0.3636	0.2000	0.1455	0.0407
	bert_Last1avg(+作文,+whitening)	0.3097	0.3454	0.4090	0.6803	0.7177	0.3636	0.2364	0.1727	0.0426

R@all 表示全部小类中离题的召回

+作文 表示在作文数据上进行微调 (原始模型使用新闻数据预训练)

+whitening 表示使用Bert-whitening对表示进行变换

\* lstm\_h<sub>tn</sub> 表示取Lstm最后时刻的表示, lstm\_avg 表示取Lstm所有时刻的表示平均

Table 6: 聚类方案三 (prompt-independent) 指标更新 (英文)

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	tfidf									
	doc2vec	0.1369	0.1993	0.2476	0.5299	0.6344	0.6000	0.6000	0.5100	0.4823
分类模型	lstm	0.1313	0.1989	0.2483	0.5323	0.6215	0.4000	0.4800	0.4800	0.4328
	lstm(+测试主题)	0.1207	0.1857	0.2368	0.4925	0.5869	0.5000	0.5000	0.4400	0.3906
	bert_CLS									
	bert_CLS(+whitening)									
	bert_CLS(+测试主题)									
	bert_CLS(+测试主题,+whitening)									
生成模型	bert_Last1avg	0.1081	0.1576	0.2123	0.3992	0.4927	0.4000	0.4200	0.4000	0.3294
	bert_Last1avg(+whitening)									
	bert_Last1avg(+测试主题)	0.1183	0.1794	0.2473	0.4719	0.5218	0.6000	0.5000	0.4400	0.3568
	bert_Last1avg(+测试主题,+whitening)									
	lstm_h <sub>tn</sub>	0.0962	0.1452	0.2001	0.4682	0.5370	0.4000	0.3200	0.3700	0.3994
	lstm_avg	0.1293	0.1738	0.2275	0.4096	0.5114	0.5000	0.4600	0.4400	0.3856
	bert_CLS	0.1313	0.1989	0.2483	0.5323	0.6215	0.4000	0.4800	0.4800	0.4328
	bert_CLS(+whitening)									
	bert_CLS(+测试作文)	0.0327	0.0475	0.0621	0.1054	0.1244	0.2000	0.1400	0.1200	0.0248
	bert_CLS(+测试作文,+whitening)									
生成模型	bert_Last1avg	0.1333	0.1812	0.2581	0.6099	0.7734	0.6000	0.5400	0.4600	0.5095
	bert_Last1avg(+whitening)									
	bert_Last1avg(+测试作文)	0.0519	0.0665	0.0857	0.1460	0.1901	0.5000	0.2800	0.2000	0.0378
	bert_Last1avg(+测试作文,+whitening)									
	bert_Last1avg(+测试作文,+whitening)									

+测试主题 表示在测试主题继续训练分类模型；+测试作文 表示在测试集上继续训练生成模型  
\* lstm\_h<sub>tn</sub> 表示取Lstm最后时刻的表示，lstm\_avg 表示取Lstm所有时刻的表示平均

Table 7: 聚类方案三（prompt-independent）指标更新（中文）

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	baseline	-	-	-	-	-	-	-	-	-
	tfidf	0.3692	0.4654	0.5496	0.7094	-	0.4545	0.2909	0.2182	0.2719
	doc2vec	0.2430	0.3175	0.3175	0.8093	-	0.0909	0.1273	0.1273	0.1525
分类模型	lstm	0.2894	0.3487	0.4093	0.6328	-	0.6364	0.2364	0.1727	0.1239
	bert_CLS	0.4136	0.4934	0.5267	0.6738	-	0.2727	0.2364	0.2000	0.0835
	bert_CLS(+whitening)	0.1924	0.2387	0.3501	0.6827	-	0.0000	0.0909	0.1091	0.0541
	bert_Last1avg	<b>0.4781</b>	0.5062	0.5820	0.6988	-	0.4545	0.2727	0.2364	0.1102
	bert_Last1avg(+whitening)	0.1621	0.2357	0.3175	0.6774	-	0.0000	0.0909	0.1000	0.0055
	bert_Last2avg	0.4296	0.5668	0.5722	0.6988	-	0.2727	0.2182	0.2182	0.1165
生成模型	bert_Last2avg(+whitening)	0.1318	0.3266	0.3750	0.6114	-	0.0000	0.0545	0.0818	-0.0057
	lstm_h <sub>tn</sub>	0.1188	0.2258	0.2410	0.5829	-	0.0000	0.0909	0.0727	0.0161
	lstm_avg	0.2699	0.3002	0.3153	0.6988	-	0.3636	0.1818	0.1727	0.1398
	lstm_h <sub>tn</sub> (+作文)	0.1469	0.2312	0.3608	0.6738	-	0.0000	0.0727	0.0909	0.0796
	lstm_avg(+作文)	0.2629	0.3137	0.3494	0.6578	-	0.0909	0.1636	0.1364	0.0499
	bert_CLS	0.3273	0.3879	0.4039	0.7398	-	0.0909	0.2000	0.1545	0.1629
	bert_CLS(+whitening)	0.1861	0.2380	0.3289	0.6524	-	0.0909	0.0909	0.1000	0.0040
	bert_CLS(+作文)	0.4328	0.4435	0.4889	0.6488	-	0.4545	0.3636	0.2364	0.1981
	bert_CLS(+作文,+whitening)	0.2203	0.3091	0.3879	0.6524	-	0.0000	0.1091	0.1182	0.0477
	bert_Last1avg	0.3523	0.3911	0.4578	0.7201	-	0.2727	0.2545	0.1727	0.2072
	bert_Last1avg(+whitening)	0.1309	0.2743	0.3683	0.6578	-	0.0909	0.0909	0.0727	-0.0178
	bert_Last1avg(+作文)	0.4328	0.4738	0.4889	0.6435	-	0.4545	0.3818	0.2364	0.2241
	bert_Last1avg(+作文,+whitening)	0.1296	0.2508	0.3144	0.8093	-	0.0909	0.0727	0.0909	-0.0366
	bert_Last1avg(+作文,+whitening)									

R@all 表示全部小类中离题的召回  
+作文 表示在作文数据上进行微调（原始模型使用新闻数据预训练）  
+whitening 表示使用Bert-whitening对表示进行变换  
\* lstm\_h<sub>tn</sub> 表示取Lstm最后时刻的表示，lstm\_avg 表示取Lstm所有时刻的表示平均  
prompt 没有baseline特征

Table 8: 聚类方案四指标更新（英文）

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	tfidf	0.0258	0.0467	0.0732	0.1987	-	0.0000	0.1000	0.0900	0.0878
	doc2vec	0.0604	0.0693	0.0881	0.1985	-	0.4000	0.2400	0.2300	0.0627
分类模型	lstm	0.0210	0.0391	0.0448	0.0994	-	0.2000	0.1000	0.0700	-0.0148
	lstm(+测试主题)	0.0150	0.0196	0.0419	0.1358	-	0.0000	0.0600	0.0500	-0.0120
	bert_CLS	0.0398	0.0575	0.0730	0.1946	-	0.2000	0.1600	0.1400	0.1041
	bert_CLS(+whitening)	0.0120	0.0147	0.0251	0.0975	-	0.2000	0.0400	0.0400	0.0025
	bert_CLS(+测试主题)	0.0483	0.0892	0.1149	0.2613	-	0.2000	0.2400	0.1800	0.1450
	bert_CLS(+测试主题,+whitening)	0.0272	0.0352	0.0421	0.1175	-	0.1000	0.0800	0.0800	0.0206
	bert_Last1avg	0.0480	0.0601	0.0848	0.2034	-	0.2000	0.1800	0.1700	0.1026
	bert_Last1avg(+whitening)	0.0190	0.0218	0.0252	0.0828	-	0.0000	0.0400	0.0600	0.0055
	bert_Last1avg(+测试主题)	0.0864	0.1072	0.1254	0.2750	-	0.2000	0.2200	0.3000	0.1685
	bert_Last1avg(+测试主题,+whitening)	0.0110	0.0175	0.0286	0.0866	-	0.0000	0.0200	0.0400	0.0173
生成模型	lstm(取最后时刻的表示)	0.0349	0.0543	0.0808	0.1682	-	0.2000	0.1000	0.1200	0.0792
	lstm(取全部时刻的表示平均)	0.0551	0.0686	0.0802	0.1398	-	0.2000	0.1800	0.2100	-0.0003
	bert_CLS	0.0608	0.0901	0.1033	0.2167	-	0.5000	0.3200	0.2400	0.0854
	bert_CLS(+whitening)	0.0305	0.0406	0.0453	0.0921	-	0.1000	0.1200	0.1000	0.0116
	bert_CLS(+测试作文)	0.0313	0.0523	0.0730	0.1453	-	0.3000	0.1400	0.1200	0.0400
	bert_CLS(+测试作文,+whitening)	0.0300	0.0393	0.0503	0.1140	-	0.0000	0.0800	0.1100	0.0240
	bert_Last1avg	0.0547	0.0682	0.0768	0.1580	-	0.0000	0.2000	0.2100	0.0489
	bert_Last1avg(+whitening)	0.0189	0.0357	0.0506	0.1107	-	0.2000	0.0800	0.0700	-0.0111
	bert_Last1avg(+测试作文)	0.0501	0.0631	0.0796	0.1398	-	0.6000	0.2600	0.1900	0.0249
	bert_Last1avg(+测试作文,+whitening)	0.0145	0.0243	0.0374	0.0951	-	0.1000	0.0600	0.0400	0.0033

+测试主题 表示在测试主题继续训练分类模型；+测试作文 表示在测试集上继续训练生成模型  
\* lstm\_h<sub>t<sub>n</sub></sub> 表示取Lstm最后时刻的表示，lstm\_avg 表示取Lstm所有时刻的表示平均

Table 9: 聚类方案四指标更新（中文）

## A 附录

### A.1 数据集

#### A.1.1 中文数据集

- 数据来源：智学网作文
  - 数据信息：
    - 共35个主题(18个命题作文，17个半命题作文)，61102篇作文
    - 35个主题信息，见表
    - 各档分数分布，见表
- \* 离题数据划分：1、2、3档作文划分为离题作文/4档划分为切题作文

题目	离题作文数	切题作文数	合计	题目	离题作文数	切题作文数	合计	题目	离题作文数	切题作文数	合计
我的心情我做主	99	3371	3470	补你一个_____	24	291	315	你_____的样子，真美	361	336	1372
那一刻，我_____	40	2240	2280	记忆中的温暖	36	2321	2357	_____给我印象最深	48	1452	1500
你，就这样留在了我的记忆里	23	3143	3166	幸福就在身边	33	2598	2631	你是我的偶像	86	1591	1677
那曾经感动我的爱	43	1336	1379	我多想_____	26	484	510	我美丽，因为我_____	39	2308	2347
那一件令我_____的事	44	1232	1276	我心中的那一缕阳光	41	1291	1332	_____的滋味	34	1031	1065
天津风格	45	1156	1201	我感受到了_____的魅力	115	3174	3289	重拾幸福	43	2290	2333
我想去_____	40	1544	1584	我为_____点赞	37	222	259	面对，我为自己竖起大拇指	39	2284	2323
有你的日子，春风十里	39	1799	1838	我体验到_____	41	1528	1569	原来我不懂	43	3040	3083
点滴真情	36	2510	2546	朴实的身影	39	737	776	心中有个梦	45	495	540
我在_____中得到快乐	29	445	474	志当存高远	41	771	812	成长的烦恼	39	1515	1554
留在心中的精彩	41	268	309	_____，我的期待	72	5269	5341	_____的魅力	31	951	982
我品尝了_____的滋味	38	3053	3091	记住这一天	37	484	521				

Table 10: 中文35个主题信息

	score=1	score=2	score=3	score=4	合计	离题：切题
标注数据	544	496	502	574	2116	0.3722
补充数据	544	496	502	59560	61102	38.6252
random_10	108	104	138	5148	5498	14.7086

Table 11: 中文数据集各档分数分布

### A.1.2 英文数据集

- 数据来源：ICLE公开数据集
- 数据信息：
  - 共13个主题（使用11个主题），830篇作文
  - 13个主题信息，见表
  - 五折主题划分，见表

prompt	离题作文数	作文数
Some people say that in our modern world, dominated by science and technology and industrialisation, there is no longer a place for dreaming and imagination. What is your opinion?	17	237
Most university degrees are theoretical and do not prepare students for the real world. They are therefore of very little value	1	131
Poverty is the cause of the HIV/AIDS epidemic in Africa.	0	1
Marx once said that religion was the opium of the masses. If he was alive at the end of the 20th century, he would replace religion with television	7	13
Feminists have done more harm to the cause of women than good	3	49
The prison system is outdated. No civilized society should punish its criminals: it should rehabilitate them	3	80
In the words of the old song: 'Money is the root of all evil'	5	71
In his novel 'Animal Farm' George Orwell wrote 'All men are equal but some are more equal than others'. How true is this today?	3	64
All armies should consist entirely of professional soldiers: there is no value in a system of military service	6	43
Crime does not pay	0	28
Most University degrees are theoretical and do not prepare us for the real life. Do you agree or disagree?	3	53
Television is the opium of the masses in modern society. Discuss.	3	58
South African soccer players should be paid more to ensure that they play in South Africa	1	2
合计	52	778

\*去除灰色主题

Table 12: 英文13个主题信息

score	1	1.5	2	2.5	3	3.5	4	合计	离题:切题
原始数据	0	0	8	44	105	230	443	830	14.96
测试数据	0	0	8	43	104	230	442	827	15.22

Table 13: 中文数据集各档分数分布

	主题数	作文数
一折(0)	1	237
二折(1,3)	2	144
三折(5,6)	2	151
四折(4,7,9)	3	141
五折(8,10,11)	3	154

Table 14: 英文五折主题划分

## A.2 模型

- TF-IDF
  - 英文：IDF在ICLE全部作文上计算（共9529篇作文），共20562个分词

- 中文：IDF在全部测试作文上计算（共61102篇作文），共27592个分词
- Doc2vec
  - 英文：在ICLE全部作文上训练， $dim = 200$
  - 中文：在智学网作文数据上训练， $dim = 200$
- 分类模型(HBiLstm / BERT)
  - 英文：
    - \* ICLE数据集，70个主题，数据分布见表
  - 中文：
    - \* 智学网初中作文，共330个主题，数据分布见表
- 生成模型(BiLstm / BERT)
  - 英文：
    - \* Xsum新闻数据上训练，在作文数据上继续训练
  - 中文：

	训练集	验证集	测试集	合计
中文(智学网作文)	127507	15949	16055	159511
英文(ICLE数据集)	2811	349	388	3548

Table 15: 分类模型数据分布

	训练集	验证集	测试集	合计
中文(乐乐课堂)	828462	300	300	829062
英文(xsum)	214352	11333	11333	237018
英文(作文)	1931	20	20	1971

Table 16: 生成模型数据分布

### A.3 distance\_threshold、example\_threshold和R@\_变化趋势

- 见图

### A.4 方案一算法

### A.5 中文35个主题指标



The prison system is outdated. No civilized society should punish its criminals: it should rehabilitate them




Figure 1: distance\_threshold、example\_threshold、R@10变化趋势(BERT分类模型[CLS])

The prison system is outdated. No civilized society should punish its criminals: it should rehabilitate them




Figure 2: distance\_threshold、example\_threshold、R@all变化趋势(BERT分类模型[CLS])

**Algorithm 1** Clustering-based Essay Topical Relevance Assessment**Input:** $V$  : A list of feature vectors for essays from a given prompt; $T$  : Similarity threshold for agglomerative clustering;**ExemplarChecker**: A function to check whether an essay cluster could be viewed as a topic exemplar.**Output:** $R$  : Essays ranked according to the probability of being off-topic.

- 1: Applying AgglomerativeClustering algorithm to cluster  $V$  into clusters  $\{C_1, \dots, C_m\}$  with the Similarity constraint  $T$ .
- 2:  $E = []$  // Topic Exemplars
- 3:  $O = []$  // Outliers
- 4: **for** each cluster  $C_i$  **do**
- 5:   **if** ExemplarChecker( $C_i$ ) is True **then**
- 6:      $E.append(C_i)$
- 7:   **else**
- 8:      $O.append(C_i)$
- 9:   **end if**
- 10: **end for**
- 11:  $S = []$  // Scores
- 12: **for**  $x$  in  $O$  **do**
- 13:    $score(x) = \max_{C_i \in E} (Sim([x], C_i))$
- 14:    $S.append(score(x))$
- 15: **end for**
- 16:  $R = \text{Ranking}(O, S)$  // Rank  $O$  according to  $S$  in ascending order
- 17: **return**  $R$

		R@10	R@15	R@20	R@50	R@all	P@1	P@5	P@10	spearman
	tfidf									
	doc2vec	0.0593	0.0761	0.0977	0.1971	-	0.4000	0.2743	0.2343	0.1102
分类模型	lstm	0.0531	0.0719	0.0816	0.1708	-	0.2286	0.2400	0.2171	0.1133
	lstm(+测试主题)	0.0664	0.0903	0.1091	0.1976	-	0.4286	0.3143	0.2714	0.1273
	bert_CLS	0.0491	0.0643	0.0779	0.1473	-	0.3714	0.2400	0.1943	0.0920
	bert_CLS(+whitening)	0.0231	0.0315	0.0394	0.1061	-	0.0571	0.0857	0.0914	0.0869
	bert_CLS(+测试主题)	0.0570	0.0741	0.0940	0.1685	-	0.2286	0.2457	0.2257	0.1059
	bert_CLS(+测试主题,+whitening)	0.0264	0.0367	0.0468	0.1103	-	0.0857	0.1029	0.1057	0.0966
	bert_Last1avg	0.0531	0.0704	0.0855	0.1629	-	0.3143	0.2514	0.2057	0.0880
	bert_Last1avg(+whitening)	0.0252	0.0371	0.0509	0.1187	-	0.1143	0.1143	0.0971	0.0940
	bert_Last1avg(+测试主题)	0.0622	0.0908	0.1105	0.1963	-	0.4571	0.2914	0.2400	0.1188
	bert_Last1avg(+测试主题,+whitening)	0.0284	0.0419	0.0614	0.1436	-	0.1143	0.1086	0.1114	0.1136
生成模型	lstm_h <sub>tn</sub>	0.0081	0.0126	0.0162	0.0479	-	0.0000	0.0457	0.0343	0.0123
	lstm_avg	0.0442	0.0607	0.0734	0.1408	-	0.2000	0.2057	0.1743	0.0810
	bert_CLS	0.0560	0.0736	0.0860	0.1426	-	0.3143	0.2686	0.2257	0.0666
	bert_CLS(+whitening)	0.0364	0.0472	0.0605	0.1185	-	0.0571	0.1371	0.1429	0.0858
	bert_CLS(+测试作文)	0.0312	0.0414	0.0522	0.1064	-	0.2286	0.1600	0.1314	0.0410
	bert_CLS(+测试作文,+whitening)	0.0289	0.0415	0.0514	0.1172	-	0.0857	0.1143	0.1143	0.0757
	bert_Last1avg	0.0350	0.0433	0.0535	0.1061	-	0.1714	0.1429	0.1371	0.0581
	bert_Last1avg(+whitening)	0.0271	0.0379	0.0492	0.1140	-	0.0857	0.1086	0.1114	0.0846
	bert_Last1avg(+测试作文)	0.0401	0.0510	0.0596	0.1129	-	0.3714	0.1943	0.1686	0.0438
	bert_Last1avg(+测试作文,+whitening)	0.0292	0.0422	0.0512	0.1080	-	0.0571	0.1600	0.1114	0.0697

R@all 表示全部小类中离题的召回

+测试主题 表示在测试主题继续训练分类模型

+测试作文 表示在测试集上继续训练生成模型

+whitening 表示使用Bert-whitening对表示进行变换

\* lstm\_h<sub>tn</sub> 表示取Lstm最后时刻的表示, lstm\_avg 表示取Lstm所有时刻的表示平均

Table 17: 聚类方案二 (one-class) 指标更新 (中文-35主题)

		<b>R@10</b>	<b>R@15</b>	<b>R@20</b>	<b>R@50</b>	<b>R@all</b>	<b>P@1</b>	<b>P@5</b>	<b>P@10</b>	<b>spearman</b>
<b>tfidf</b>										
<b>doc2vec</b>		0.0356	0.0480	0.0635	0.1269	-	0.2857	0.1429	0.1400	0.0440
分类模型	<b>lstm</b>	0.0104	0.0182	0.0219	0.0468	-	0.0857	0.0457	0.0371	-0.0172
	<b>lstm(+测试主题)</b>	0.0086	0.0114	0.0207	0.0616	-	0.0286	0.0286	0.0343	-0.0190
	<b>bert_CLS</b>	0.0219	0.0345	0.0463	0.1078	-	0.2000	0.1086	0.0886	0.0789
	<b>bert_CLS(+whitening)</b>	0.0100	0.0195	0.0249	0.0715	-	0.0000	0.0286	0.0371	0.0416
	<b>bert_CLS(+测试主题)</b>	0.0453	0.0642	0.0775	0.1580	-	0.2000	0.2171	0.1829	0.0996
	<b>bert_CLS(+测试主题,+whitening)</b>	0.0122	0.0152	0.0237	0.0634	-	0.0000	0.0286	0.0457	0.0521
	<b>bert_Last1avg</b>	0.0417	0.0543	0.0723	0.1522	-	0.3143	0.2171	0.1686	0.0919
	<b>bert_Last1avg(+whitening)</b>	0.0101	0.0142	0.0198	0.0504	-	0.0286	0.0343	0.0400	0.0267
	<b>bert_Last1avg(+测试主题)</b>	0.0582	0.0741	0.0881	0.1739	-	0.3143	0.2229	0.2286	0.1091
	<b>bert_Last1avg(+测试主题,+whitening)</b>	0.0123	0.0202	0.0289	0.0765	-	0.0857	0.0457	0.0486	0.0544
生成模型	<b>lstm_h<sub>tn</sub></b>	0.0155	0.0237	0.0334	0.0669	-	0.0571	0.0571	0.0629	0.0259
	<b>lstm_avg</b>	0.0236	0.0309	0.0363	0.0649	-	0.1714	0.0857	0.0943	-0.0215
	<b>bert_CLS</b>	0.0580	0.0765	0.0874	0.1544	-	0.3429	0.2800	0.2429	0.0813
	<b>bert_CLS(+whitening)</b>	0.0121	0.0146	0.0174	0.0480	-	0.0000	0.0400	0.0457	0.0081
	<b>bert_CLS(+测试作文)</b>	0.0303	0.0428	0.0548	0.1030	-	0.2000	0.1371	0.1286	0.0338
	<b>bert_CLS(+测试作文,+whitening)</b>	0.0099	0.0142	0.0175	0.0503	-	0.0571	0.0286	0.0371	0.0106
	<b>bert_Last1avg</b>	0.0313	0.0411	0.0507	0.1003	-	0.1143	0.1600	0.1371	0.0489
	<b>bert_Last1avg(+whitening)</b>	0.0076	0.0119	0.0171	0.0460	-	0.0286	0.0286	0.0286	0.0012
	<b>bert_Last1avg(+测试作文)</b>	0.0400	0.0486	0.0607	0.1139	-	0.3714	0.1771	0.1657	0.0237
	<b>bert_Last1avg(+测试作文,+whitening)</b>	0.0131	0.0170	0.0214	0.0534	-	0.0571	0.0400	0.0457	0.0097

R@all 表示全部小类中离题的召回

+作文 表示在作文数据上进行微调（原始模型使用新闻数据预训练）

+whitening 表示使用Bert-whitening对表示进行变换

\* lstm\_h<sub>tn</sub> 表示取Lstm最后时刻的表示，lstm\_avg 表示取Lstm所有时刻的表示平均

Table 18: 聚类方案四指标更新（中文-35主题）